



UNIVERSIDADE
FEDERAL DO CEARÁ

Curso de Engenharia da Computação

UFC - Sobral

Projeto Final - PDS

Segmentação e Classificação de Ressonância Magnética

Magdiel Campelo Alves de Sousa - 363689

Sobral, CE, 15 de dezembro de 2016

Sumário

1.	Introdução	3
2.	Trabalhos Relacionados	4
2.1.	Metodologia de Patil e Bhalchandra	4
2.2.	Metodologia de SivaSankari et al.	5
3.	Fundamentação Teórica	6
3.1.	Filtros Digitais Espaciais	6
3.2.	Segmentação de imagens	7
3.2.1.	K-Means Cluster	7
3.3.	Extração de características	8
3.3.1.	GLCM - <i>Graylevel Co-occurrence Matrix</i>	8
3.4.	Classificação de imagens	9
4.	Metodologia	10
5.	Resultados e discussões	14
6.	Conclusão	15
7.	Referências	16

1. Introdução

As imagens por ressonância magnética (IRM) são ferramentas importantes no tratamento de tumor cerebral, já que constituem um método não invasivo para visualização das estruturas internas do cérebro e apresentam alta resolução anatômica. A IRM é normalmente a técnica de imagem escolhida para avaliação do crescimento do tumor, planejamento da cirurgia e seguimento da quimioterapia e radioterapia. A segmentação da área do tumor permite a quantificação do volume de massa e sua resposta ao tratamento, entretanto, é, com frequência, realizada manualmente, o que causa demora e dificuldade na execução, levando a dois problemas principais: baixa resposta a mudanças pequenas e alta variabilidade entre segmentações diferentes. Os sistemas computacionais podem facilitar a carga manual segmentada enquanto se mostram como ferramenta de fácil avaliação do desenvolvimento da massa tumoral.

Este estudo apresenta método de segmentação de tumor cerebral em IRM que tem por objetivo a segmentação das massas tumorais em IRM com resultados reproduzíveis e a extração de características da imagem para classificação. Foi utilizado técnicas de agrupamento iterativo que classificam objetos em um determinado número de classes para segmentação da imagem, e, para extrair informações e características das massas tumorais, foi utilizado a matriz de co-ocorrência da imagem e então derivado informações da mesma, que tem como principal uso analisar a textura da imagem. A partir de um banco de dados classificados em tumores benigno e maligno foi feita a classificação utilizando redes neurais artificiais de múltiplas camadas.

Neste trabalho, descreveu-se um sistema computacional feito em Matlab, apresentando resultados empíricos, e discutiram-se os prós e contras do sistema adotado.

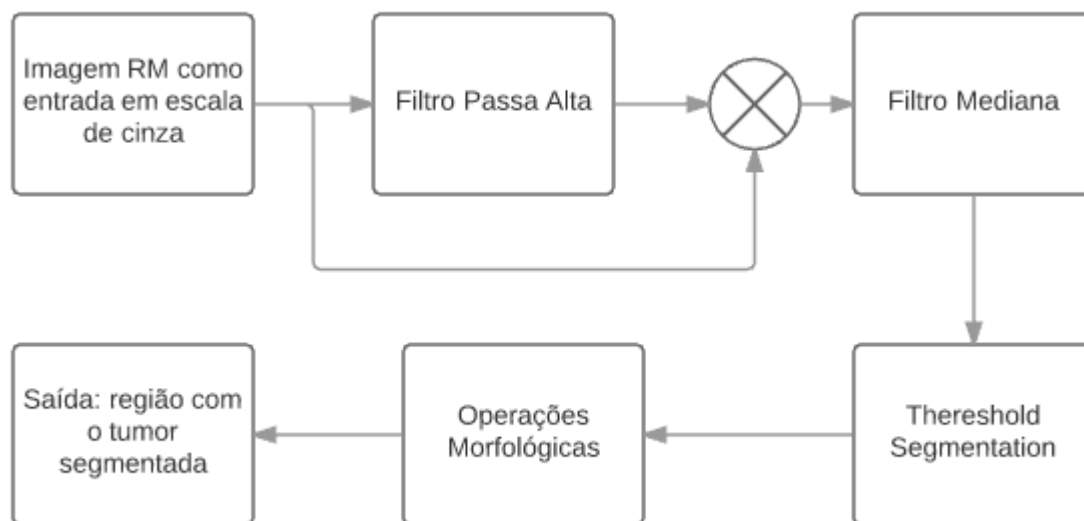
2. Trabalhos Relacionados

A realização deste projeto foi possível devido à adaptação de duas metodologias utilizadas para segmentação e extração de características de imagem de ressonância magnética. Para o pré-processamento da imagem, foi utilizado um método baseado no de Patil e Bhalchandra, descrito no artigo [1] publicado no International Journal of Electronics, Communication & Soft Computing Science and Engineering, e para segmentação da imagem e extração de características baseou-se na metodologia de SivaSankari et al, descrito no artigo [2] publicado no International Journal of Innovative Research in Science, Engineering and Technology.

2.1. Metodologia de Patil e Bhalchandra

Neste método são realizados uma série de passos, que podem ser visualizados na Figura 1 abaixo, para a segmentação da imagem, extraindo e destacando o tumor na ressonância magnética.


Figura 1: Diagrama ilustrativo do processo de segmentação



Fonte: Autor do trabalho.

Inicialmente, a imagem de ressonância magnética é convertida para escala de cinza, para que possa ser realizado as etapas de pré-processamento da imagem, em que é utilizado um filtro passa alta para realçar as bordas da imagem, somando a saída do filtro com a imagem original. Feito isso, é aplicado um filtro mediana, que elimina os ruídos de alta frequência e suaviza os tons de cinza da imagem, melhorando o processo de segmentação, como pode ser visto na Figura 2 abaixo. Após aplicado o filtro, é feito o processo de separação do tumor a partir de um limiar, binarizando a imagem, diferenciando onde é possível que tenha um tumor e onde não tem.

Figura 2: Resultado do método descrito

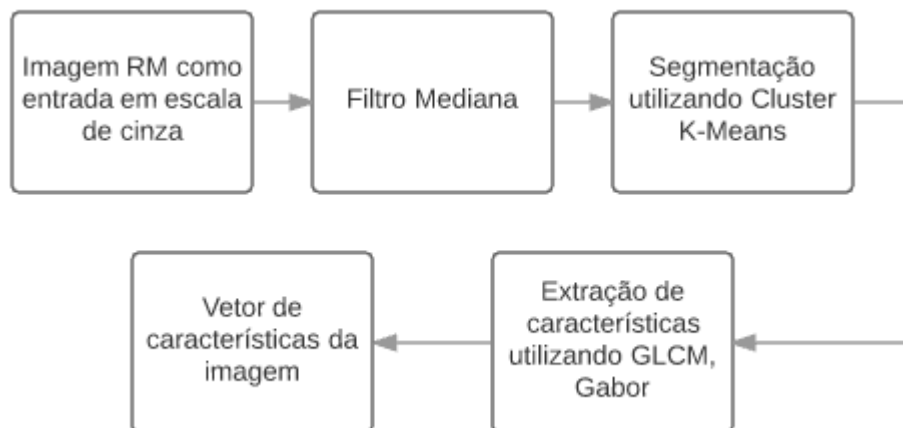


Fonte: Autor do trabalho

2.2. Metodologia de SivaSankari et al.

O propósito deste método é extrair informações das imagens de ressonância magnética, para classificação de tumores. Abaixo, na Figura 3, pode ser visto o diagrama com os passos realizados.

Figura 3: Diagrama ilustrativo do processo de segmentação e extração de característica



Fonte: Autor do trabalho

Inicialmente recebe uma imagem de ressonância magnética em escala de cinza, e então é passado apenas o filtro mediana, para a segmentação da imagem, foi utilizado a técnica de clusterização de k-médias, que separa em k classes os objetos de interesse, no caso, as tonalidades de cinza da imagem, e então separada o tom mais claro, que corresponde ao tumor do cérebro. Para extrair as características foi calculada a matriz de co-ocorrência em escala de cinza da imagem, que a partir dessa matriz pode ser inferido outras informações da imagem, que compõe o vetor de características da mesma.

3. Fundamentação teórica

Para uma melhor compreensão das técnicas abordadas, aqui será explanado alguns detalhes e uma base teórica sobre o métodos e conceitos utilizados neste trabalho.


3.1. Filtros digitais espaciais

Como está sendo trabalhado com imagens, que são sinais de duas dimensões, os filtros tradicionais tem de ser aplicados também em duas dimensões. Geralmente é utilizado filtros em imagens quando se deseja corrigir, suavizar ou realçar determinadas características de uma imagem. Assim como em sinais de uma dimensão, imagens possuem mais domínios que podem ser realizadas as operações, podendo ser trabalhada no espaço, com convolução de matrizes de transformação, ou na frequência, com multiplicação de matrizes de transformação. Neste trabalho foi utilizado como domínio de aplicação o espaço, sendo todos os filtros aplicados utilizando convolução. A filtragem é realizada pixel a pixel, onde o novo nível de cinza de um ponto P qualquer depende do seu nível de cinza original e do de outros pontos considerados como vizinhança de P.

No domínio do tempo um filtro passa alta se trata de uma matriz de números negativos com um número positivo no centro. A filtragem passa-alta realça detalhes, produzindo uma "agudização" da imagem, isto é, as transições entre regiões diferentes tornam-se mais nítidas. Estes filtros podem ser usados para realçar certas características presentes na imagem, tais como bordas, linhas curvas ou manchas, mas enfatizam o ruído existente na imagem. Alguns exemplos podem ser dado por:

$$\begin{pmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{pmatrix} \begin{pmatrix} -1 & -1 & -1 \\ -1 & 9 & -1 \\ -1 & -1 & -1 \end{pmatrix} \begin{pmatrix} 1 & -2 & 1 \\ -2 & 5 & -2 \\ 1 & -2 & 1 \end{pmatrix}$$

A aplicação desses filtros é realizada pelo processo de convolução da imagem com a matriz núcleo, que é a matriz de transformação do filtro, abaixo um exemplo simples:



O filtro lê sucessivamente, da esquerda para a direita e de cima para baixo, todos os pixels da área de ação do núcleo. Ele multiplica o valor de cada um deles pelo valor correspondente do núcleo e depois soma os resultados. O pixel inicial (50) se torna: $(40 \cdot 0) + (42 \cdot 1) + (46 \cdot 0) + (46 \cdot 0) + (50 \cdot 0) + (55 \cdot 0) + (52 \cdot 0) + (56 \cdot 0) + (58 \cdot 0) = 42$. (o filtro não trabalha diretamente sobre a imagem, mas sim em uma cópia). O filtro mediana é similar ao

passa alta exemplificado anteriormente, porém ele substitui o pixel inicial pela mediana dos valores dos pixels que são cobertos pelo núcleo.

3.2. Segmentação de imagem

Segmentação de imagem é, basicamente, separar e destacar parte da imagem para que possam ser inferidas informações sobre certa característica da imagem. No caso da imagem de ressonância magnética deseja-se extrair o tumor para que possa ser identificado. A técnica mais simples de segmentação trata-se da segmentação por limiar, em que é definido um limiar e todos os tons de cinza acima desse limiar são substituídos por 1, e o que é abaixo é substituído por 0. Uma outra maneira de segmentar imagem, que foi abordada neste trabalho é a segmentação utilizando clusterização por k-médias (*K-Means Cluster*).


3.2.1. *K-Means Cluster*

A clusterização por k-médias é um algoritmo de agrupamento iterativo que classifica objetos num determinado número predefinido K de grupos (*clusters*), tem como função de classificação a distância do objeto ao centróide do grupo, e minimiza a soma J de todas as distâncias euclidianas entre cada objeto e o seu centróide, segundo o critério de mínimos quadrados dado por:

$$J = \sum_{j=1}^k \sum_{n \in S_j} \|x_n - c_j\|^2$$

O algoritmo pode ser descrito da seguinte forma, inicialmente é determinado k centróides aleatórios, então é calculado a média, ou o centro, de cada *cluster*, feito isso será calculado para cada pixel a distância entre ele e cada centróide dos *clusters* e movido para o *cluster* de menor distância, é recalculado os centros. O processo é repetido até que os centros não se movam. Fazendo com que a imagem possua apenas o número de tonalidades referente ao número de classes. No caso da ressonância magnética, as massas tumorais apresentam maiores tons de cinza, um exemplo pode ser visualizado na Figura 4 abaixo. A extração do tumor foi realizada utilizando a técnica do limiar.

Figura 4: Exemplo de segmentação com K-Means Cluster



Fonte: SivaSankari, et al. (2014)

3.3. Extração de Características

No reconhecimento de padrões e no processamento de imagens, a extração de características é uma forma especial de redução de dimensionalidade. Quando os dados de entrada para um algoritmo são muito grandes para serem processados e suspeita-se que sejam notoriamente redundantes, então os dados de entrada serão transformados em um conjunto de características reduzidas (vetor de características). A extração do recurso é útil em identificar o tumor de cérebro onde está localizado exatamente e ajuda em prever a fase seguinte. Transformar os dados de entrada no conjunto de recursos é chamado de extração de características. Neste trabalho, uma das técnicas de extração de características utilizadas foi a matriz de co-ocorrência em escalas de cinza (GLCM, *Graylevel Co-occurrence Matrix*).

3.3.1. GLCM - *Graylevel Co-occurrence Matrix*

Uma matriz de co-ocorrência é uma tabulação de quantas combinações diferentes de valores de intensidade dos pixels (níveis de cinza) ocorrem em uma imagem. O uso principal da Matriz de Co-ocorrência é caracterizar texturas em uma imagem através de um conjunto de estatísticas para as ocorrências de cada nível de cinza em pixels diferentes ao longo de diferentes direções. As matrizes de co-ocorrência são ferramentas para a classificação de imagens. No entanto, elas possuem alto custo computacional a medida que o número de tons de cinza crescer na imagem.

A Matriz de Co-ocorrência de textura considera a relação entre dois pixels por vez, um chamado de pixel referência e o outro de pixel vizinho, podendo ser escolhido em qualquer direção. Também a vizinhança não precisa ser exatamente de 1 pixels, pode ser de qualquer valor. Cada pixel dentro da imagem torna-se o pixel referência, iniciando no canto superior esquerdo e procedendo até o inferior direito.

A matriz de co-ocorrência pode ser definida como $P(i, j, d, \theta)$ onde: i e j são pixels vizinhos de acordo com a distância d . Esta distância entre os pixels i e j é analisada de acordo com uma direção θ . Os valores possíveis para θ são 0° , 45° , 90° , 135° . Desta forma, a matriz (obrigatoriamente quadrada) de co-ocorrência, representa em cada elemento a_{ij} o número de vezes que ocorreu uma transição do nível de cinza Z_i para Z_j considerando a distância d entre os pixels vizinhos i e j na direção θ . Essas matrizes podem ser normalizadas através da divisão de cada entrada da matriz pelo número total de pares de pontos de pixels vizinhos que satisfaçam $P(i, j, d, \theta)$. Desta forma cada valor será a probabilidade de uma transição, da forma especificada θ , do nível de cinza i para o nível de cinza j , com uma distância d pixels.

Pode-se destacar algumas propriedades importantes da matriz de co-ocorrência como, toda matriz de co-ocorrência é uma matriz quadrada, o número de linhas e de colunas é igual ao nível de quantização da imagem. A matriz de co-ocorrência é simétrica ao redor da diagonal.

3.4. Classificação de imagens

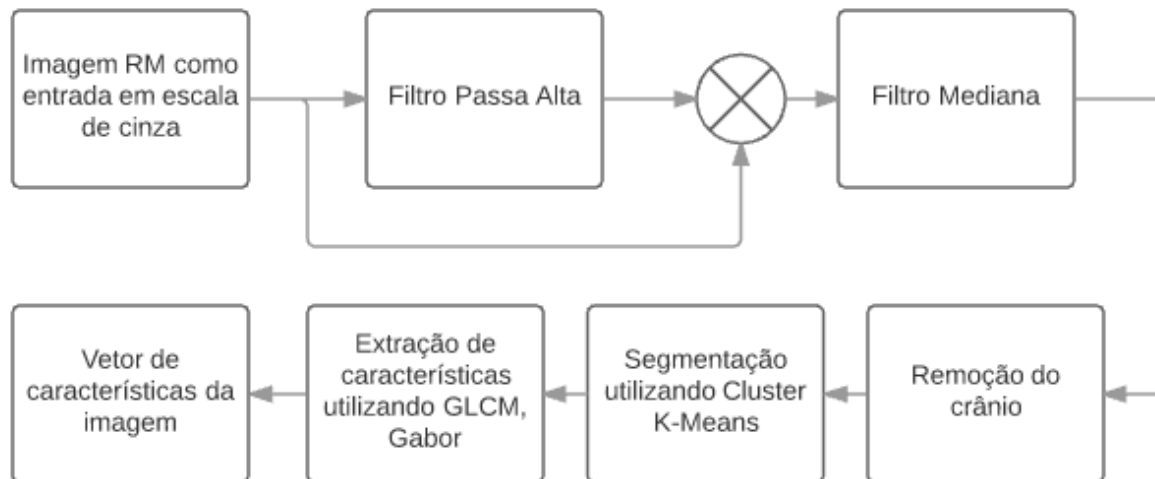
Classificação de imagens trata-se basicamente de a partir do vetor de características extraídas da imagem categorizá-las por classes para que uma nova imagem possa ser identificada a partir de um banco de testes. Um classificador adaptativo, que se molda a partir dos dados, eficiente é a rede neural de multcamadas perceptron, que foi a utilizada neste trabalho para classificar o banco de imagens disponível.

As redes neurais baseadas no modelo matemático do neurônio são treinadas a partir de um conjunto de dados, utilizando o método *backpropagation*, em que o erro é retropropagado e os pesos dos neurônios são adaptados a cada iteração a fim de minimizar o erro. Com a utilização de múltiplas camadas de neurônios, as redes conseguem separar e classificar conjuntos de dados não linearmente separáveis, que é o caso de imagens.

4. Metodologia

A metodologia adotada para o pré-processamento, segmentação e extração de características é baseada nas metodologias apresentadas na seção 2 deste trabalho. Na Figura 5 abaixo, observa-se o fluxograma da abordagem escolhida.

Figura 5: Metodologia adotada

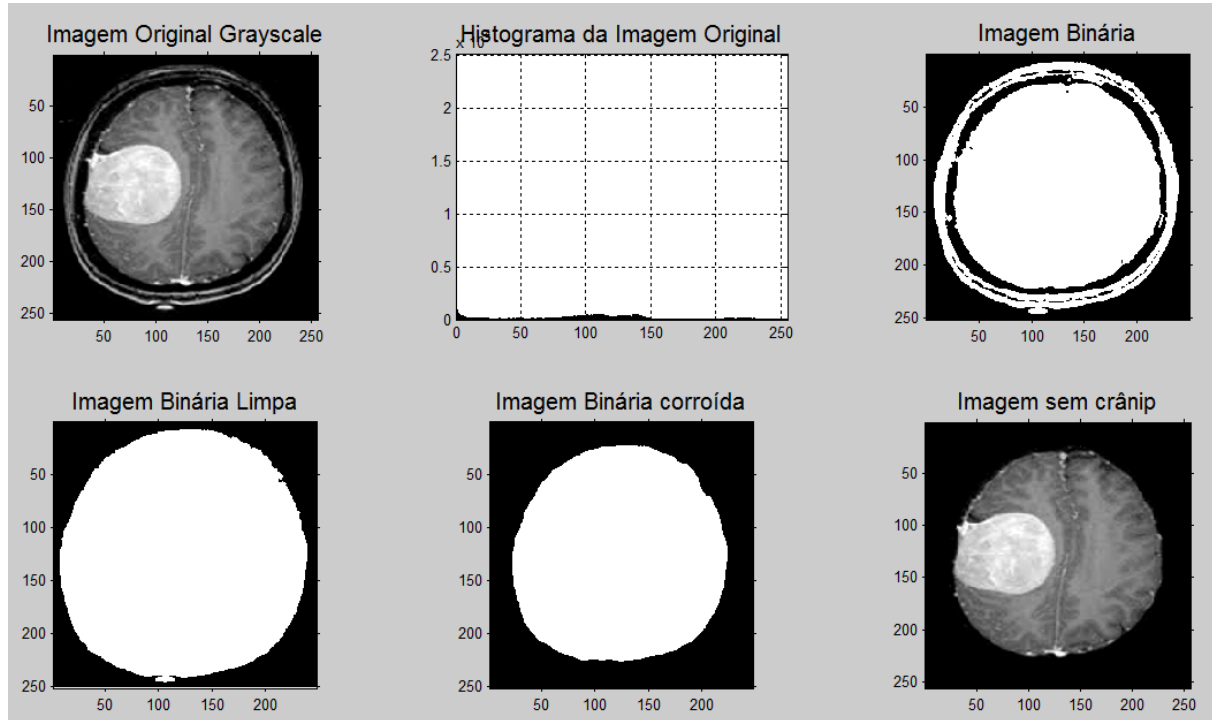


Fonte: autor do trabalho

Pode ser visto que foi feito uma junção dos dois métodos, inicialmente, tem como entrada uma imagem de ressonância magnética em escala de cinza, e ela é passada por um filtro passa alta que acentua as bordas da imagem, o filtro mediana diminui os ruídos e suaviza os tons de cinza para que a segmentação possa ser realizada.

Antes da segmentação foi realizado um processo de remoção do crânio, pois devido as tonalidades serem claras interferiam na segmentação do tumor e consequentemente na classificação da imagem. O processo de remoção do crânio consiste em uma série de passos, inicialmente binariza-se a imagem utilizando a técnica do limiar, com um limiar baixo para pegar o maior número de informações sem confundir a imagem com o fundo, e então essa imagem binária é preenchida, para que do contorno para o centro possua o menor número de espaços vazios possíveis, pois a técnica de corrosão da imagem atua nas bordas da imagem binarizada diminuindo sua área de forma uniforme, sem perder as características de sua forma. Após corroída o suficiente para remover o crânio, o complemento dessa imagem binarizada é aplicado como máscara na imagem original, removendo então o crânio da imagem, como pode ser visualizado na Figura 6 abaixo.

Figura 6: Processo de remoção de crânio



Fonte: Autor do trabalho.

Após o processo de remoção do crânio, é realizado a segmentação da imagem. Em um primeiro momento foi realizado a segmentação utilizando apenas o limiar, porém essa técnica não eliminava bem algumas partes que não faziam parte do tumor, sendo então adotada a técnica de segmentação por clusterização de k-médias, em que foi determinado um número de 3 classes para a clusterização da imagem, e então a classe mais clara foi extraída da imagem utilizando o limiar, fornecendo uma imagem segmentada de mais qualidade.

Com a imagem segmentada, e o tumor extraído da ressonância magnética do cérebro, pode ser então aplicada a técnica de extração de características baseada no GLCM. Com essa matriz extraída, foi calculada a partir dela algumas informações da imagem, como:

Contraste, que é definido como a separação entre a área mais escura e a mais clara, dada pela fórmula a seguir.

$$C = \sum_{i,j=0}^{n-1} P_{ij} (i-j)^2$$

Homogeneidade, que é definido como a qualidade ou o estado de ser homogêneo, dado por:

$$H = \sum_{i,j=0}^{n-1} \frac{P_{ij}}{1+(i-j)^2}$$

Entropia, que é medida como a incerteza de uma variável aleatória, dada por:

$$E_p = \sum_{i,j=0}^{n-1} \frac{P_{ij}}{1+(i-j)^2}$$

Energia, que provém a soma do quadrado dos elementos na GLCM, também conhecida como o segundo momento angular, dado por:

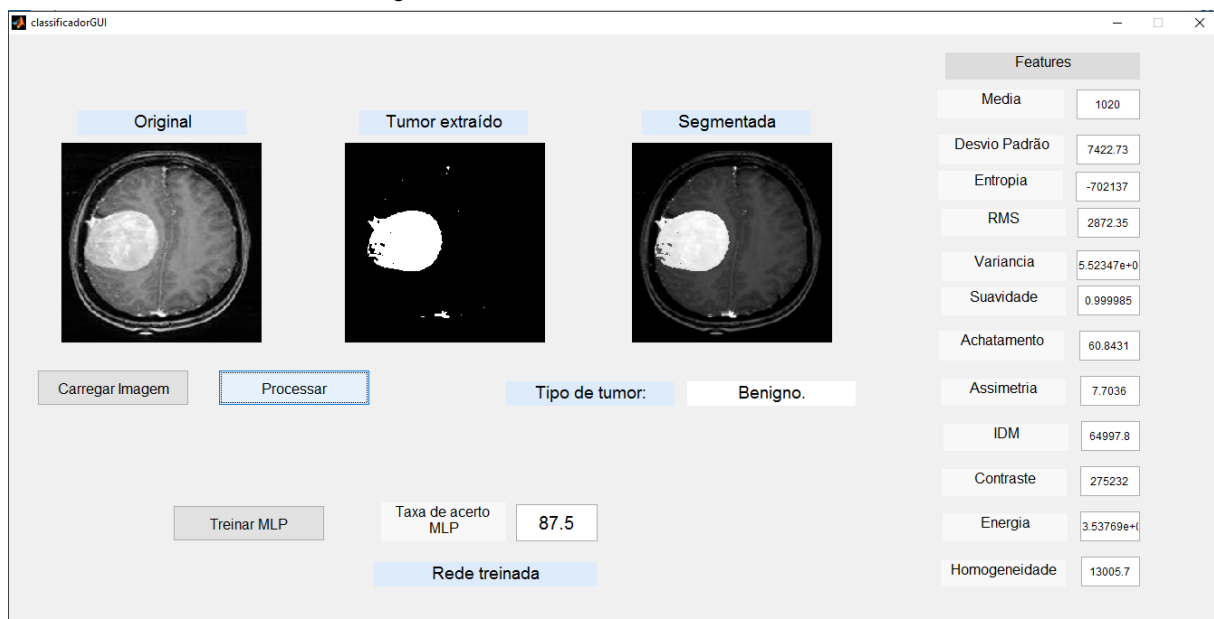
$$E_n = \sum_{i,j=0}^{n-1} (P_{ij})^2$$

Outras informações extraídas da matriz foram: média, desvio padrão, variância, rms, suavidade, achatamento, assimetria. Com essas informações foi montado o vetor de características da imagem, a partir da utilização da imagem segmentada como máscara na imagem original preservando as características de textura do tumor para uma melhor separação.

Foi criada então uma rede neural MLP, e testada várias topologias diferentes a fim de verificar o desempenho da rede, sem que os dados fossem viciados. A melhor topologia encontrada foi a de 3 subcamadas, com 15 neurônios cada. Então foi calculado o vetor de características das 24 imagens do banco de dados, divididos em duas classes (benigno e maligno), e passadas como entrada de treinamento da MLP. Por padrão, ela utiliza 60% dos dados para treinamento, 20% para validação e 20% para testes, sendo selecionadas aleatoriamente, devido a isso cada treinamento da rede gera pesos e bias diferentes, dando resultados diferentes. Para que fosse obtido um bom resultado, a rede neural é treinada várias vezes até atingir uma taxa de acerto maior que 80%, o que acontece rapidamente.

Esse método foi implementado no software Matlab, com uma interface gráfica para auxílio na visualização dos dados, que pode ser visualizada na Figura 7 abaixo.

Figura 7: Software desenvolvido em Matlab



Fonte: Autor do trabalho.

Nela, é possível carregar e visualizar a imagem original antes de ser processada, em escala de cinza, apertando o botão de carregar imagem e então, apertando o botão de processar, é possível aplicar as técnicas de segmentação e extração de características discutidas acima e visualizar o tumor extraído da imagem, bem como a imagem segmentada, com o tumor em evidência, e na lateral mostram-se todas as características que foram extraídas daquela imagem. Para que a imagem carregada possa ser identificada, como benigna ou maligna a rede neural precisa ter sido treinada, o que pode ser realizado pressionando o botão de treinar a rede.

5. Resultados e discussões

A rede neural se mostrou eficiente, utilizando a topologia de 3 camadas com 15 neurônios em cada camada, para classificação das imagens com a quantidade e a qualidade das imagens do banco de dados utilizado. O melhor resultado encontrado foi um taxa de acerto de 91.6%, e no geral entre 83% e 87%.

Em boa parte dos casos o processo de segmentação utilizado extraiu bem as massas tumorais das ressonâncias magnéticas, porém esse resultado pode ser melhorado utilizando operações morfológicas para reduzir as regiões de falso tumor.

O tempo de treinamento é um pouco demorado, devido aos parâmetros definidos para a rede neural, a fim de obter a menor taxa de erro possível, além de que roda mais de uma vez para achar uma taxa de acerto maior que 80% (definido no script), porém, no geral em até 5 iterações a rede obtém uma taxa aceitável.

As maiores dificuldades obtidas foram em relação a obtenção do banco de dados classificado e em um formato que pudesse ser tratado sem a necessidade de correção de cor e também nas técnicas de classificação, que não foi possível ser instalado, sendo que foi recorrida a rede neural por o Matlab (R2013a) já possuir a toolbox instalada.

6. Conclusão

Neste trabalho foi apresentado uma metodologia para segmentação e extração de características de imagens de ressonância magnética para identificação de massas tumorais, classificando-as como benigna ou maligna.

No geral, a técnica adotada se mostrou eficiente, dando resultados esperados. Os conceitos vistos em sala sobre processamento digital de sinais teve de ser utilizado para o caso de sinais em duas dimensões, confirmando a teoria que foi aprendida em sala, e expandindo os conhecimentos em uma área que não foi abordada em sala de aula, cumprindo os objetivos do projeto final.

Os objetivos propostos no projeto, que eram o pré-processamento da imagem de ressonância magnética, segmentação e extração da massa tumoral e obtenção de um vetor de características para classificação e identificação do tumor, foram concluídos com sucesso, com o desenvolvimento de um sistema em Matlab para tal.

7. Referências

- [1] PATIL,Rajesh C., BALCHANDRA, Dr. A. S.; Brain Tumour Extraction from MRI Images Using MATLAB; International Journal of Electronics, Communication & Soft Computing Science and Engineering;
- [2] SivaSankari.S, et al.; Feature Extraction of Brain Tumor Using MRI; International Journal of Innovative Research in Science, Engineering and Technology; Março 2014.
- [3] BOBOTOVÁ, Zuzana;Segmentation of Brain Tumors from Magnetic Resonance Images using Adaptive Thresholding and Graph Cut Algorithm; Institute of Applied Informatics Faculty of Informatics and Information Technologies Slovak University of Technology Bratislava / Slovakia
- [4] Zhang, Yudong, and Lenan Wu. "An MR brain images classifier via principal component analysis and kernel support vector machine." Progress In Electromagnetics Research 130 (2012): 369-388.
- [5] GONZALEZ, R. C.; WOODS, R. E. 3rd. Edition. Digital Image Processing, Prentice Hall, 2007. 976p.
- [6] VASCONCELOS, Simone; Matriz de co-ocorrência;
- [7] Co-occurrence matrix; Disponível em:
<https://en.wikipedia.org/wiki/Co-occurrence_matrix>